



Teknoloji Fakültesi

BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

**YAPAY ZEKÂ ALGORİTMALARI İLE
PANORAMİK DİŞ RÖNTGEN
GÖRÜNTÜLERİNDEN HASTALIK TESPİTİ**

"

BİTİRME PROJESİ

Bilgisayar Mühendisliği Bölümü

DANIŞMAN

Doç. Dr. Ayşe Berna Altınel

İSTANBUL, 2025

"



Teknoloji Fakültesi

BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

**Y APAY ZEKÂ ALGORİTMALARI İLE
PANORAMİK DİŞ RÖNTGEN
GÖRÜNTÜLERİNDEN HASTALIK TESPİTİ**

"

BİTİRME PROJESİ

Bilgisayar Mühendisliği Bölümü

DANIŞMAN

Doç. Dr. Ayşe Berna Altınel

İSTANBUL, 2025

"

MARMARA ÜNİVERSİTESİ
TEKNOLOJİ FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

Marmara Üniversitesi Teknoloji Fakültesi Bilgisayar Mühendisliği Öğrencileri İrem Selen ve Ümmügülsüm Erol tarafından “YAPAY ZEKÂ ALGORİTMALARI İLE PANORAMİK DİŞ RÖNTGEN GÖRÜNTÜLERİNDEN HASTALIK TESPİTİ” başlıklı proje çalışması, xxx tarihinde savunulmuş ve jüri üyeleri tarafından başarılı bulunmuştur.

Jüri Üyeleri

Dr. Öğr. Üyesi xxx xxx
Marmara Üniversitesi
Prof. Dr. Xxx xxx
Marmara Üniversitesi
Prof. Dr. Xxx xxx
Marmara Üniversitesi

(Danışman)

(Üye)

(Üye)

(İMZA).....

(İMZA).....

(İMZA).....

ÖNSÖZ

Proje çalışmamız süresince karşılaştığım bütün problemlerde, sabırla yardım ve bilgilerini esirgemeyen, tüm desteğini sonuna kadar yanımda hissettiğim değerli hocamız, sayın Doç. Dr. Ayşe Berna Altınel Girgin'e en içten teşekkürlerimizi sunarız.

İÇİNDEKİLER

1. GİRİŞ.....	1
1.1. Proje Çalışmasının Amacı ve Önemi.....	1
2. DİŞ RÖNTGEN GÖRÜNTÜLERİNİN SINIFLANDIRILMASINDA MAKİNE ÖĞRENMESİ UYGULAMALARI.....	2
3. VERİ SETLERİ.....	4
3.1. Dental Radiography Veri Seti	4
3.2. Dental X-Ray Panoramic Dataset Veri Seti	5
4. BULGULAR VE TARTIŞMA.....	7
4.1. Dental Radiography Veri Seti Deney ve Sonuçları.....	7
4.2. Dental X-Ray Panoramic Dataset Veri Seti Deney ve Sonuçları.....	9
4.3. Hazır Model Kullanımı.....	14
5. SONUÇLAR.....	16

ÖZET

YAPAY ZEKÂ DESTEĞİ İLE PANORAMİK DİŞ RÖNTGENLERİNDEN HASTALIK TESPİTİ

Bu proje çalışmasında, etiketlenmiş ve sınıflandırılmış 3D panoramik dental röntgen görüntülerini CNN ve YOLO gibi yöntemlerle eğiterek hastalık tespiti yapmak amaçlanmıştır. Yapay zekâ modelleri oluşturulup sonuçları test edilerek performansları incelenmiş ve sonuçlar karşılaştırılmıştır. Bu sonuçlar incelenip çalışma için en performanslı model tercih edilerek yüksek doğruluklu sonuçlara ulaşmak hedeflenmiştir. Kullanıcı tarafından girilen panoramik diş röntgenlerinin çıktı olarak hastalıklı diş tespiti yapması amaçlanmış, ilk aşamada nesne tespiti ve sınıflandırma çalışmaları yapılarak sonraki adımlarda çalışmanın hastalık sınıfları odağında daraltılması hedeflenmiştir.

Haziran, 2025

Öğrenciler

ABSTRACT

DISEASE DETECTION FROM PANORAMIC DENTAL X-RAYS WITH ARTIFICIAL INTELLIGENCE

The aim of this project is to train labeled and classified 3D panoramic dental x-ray images with CNN and YOLO methods for disease detection. Artificial intelligence models were created and their results were tested and their performances were analyzed and the results were compared. These results were analyzed and the most efficient model was chosen for the study to achieve high accuracy results. It is aimed to detect diseased teeth as an output of panoramic dental x-rays entered by the user, and it is aimed to narrow the study in the focus of disease classes in the next steps by performing object detection and classification studies in the first stage.

June, 2024

Students

KISALTMALAR

CLAHE	: Contrast Limited Adaptive Histogram Equalization
CUDA	: compute unified device architecture
CNN	: Convolutional Neural Networks
YOLO	: You Only Look Once
GPU	: graphical processing unit
CPU	: central processing unit
AI	: Artificial Intelligence
R-CNN	: Region-based Convolutional Neural Networks
FDA	: Food and Drug Administration
BBOX	: Bounding Box
ING	: ingilizce
IoU	: Intersection over Union
OpenCL	: open computing language
PTX	: parallel thread execution
SDK	: Software Development Kit
SRAM	: static random-access memory
SIMD	: single instruction multiple data
STORM	: stochastic optical reconstruction microscopy

ŞEKİL LİSTESİ

Şekil 4.1 İlk denenen basit CNN modelinin mimarisi	7
Şekil 4.2 Bounding box kullanılarak eğitilen nesne tespitli model mimarisi.....	8
Şekil 4.3 Model v.2'nin dışarıdan bir veriyle yapılmış test sonuçları.....	9
Şekil 4.4 Modelin rastgele iki test verisi üzerindeki çıktıları.....	10
Şekil 4.5 Modelin sınıf bazlı performans metrikleri	11
Şekil 4.6 Confusion Matrix.....	12
Şekil 4.7 Precision, Recall, Confidence, F1 Grafikleri	13

TABLO LİSTESİ

Tablo 4.1 İlk modelin performans metrikleri

6

1. GİRİŞ

Herkesin hayatında en az bir kere deneyimlediği diş rahatsızlıkları birçok insanın günlük yaşantısını olumsuz etkilemektedir. Hastaların randevu bulamama, yanlış/eksik teşhislere maruz kalma, fiziki ve coğrafi yetersizlikler gibi sebeplerle mağdur olduğu birçok durum karşımıza çıkmaktadır. Yapay zekâ çağı olarak nitelendirdiğimiz günümüz koşullarında her yanımız yapay zekâ araçlarıyla çevrili; yapay zekâ destekli uygulamalar, yapay zeka destekli projeler, günlük hayatımızdan profesyonel iş hayatımıza kadar yaşantımızın bir parçası haline gelmiş durumdadır. Kimi zaman basit gündelik ihtiyaçlarımızı kolaylaştıran yapay zekâ kimi zaman da teknolojik gelişmeler için bize kapıyı açan bir yol gösterici olmaktadır.

Teknolojik ilerlemenin öneminin en kritik olduğu alanlardan biri olan sağlık alanına da her geçen gün önemli yenilikler gelmektedir, buna rağmen devam eden ve ihtiyaç duyulan çalışmaların ihtiyacı ciddi ölçüde fazladır. Röntgen görüntülerinden hastalık tespiti birçok sağlık dalında hakkında çalışmalar yürütülen bir alandır. Beyin, iç organlar vb. röntgen çalışmalarıyla yapılan tümör, hastalık gibi durumların teşhisi konusunda yapılan çalışmalar oldukça popülerdir. Diş röntgenleriyle yapılan benzer çalışmalar bu alanlara göre daha az sayıdadır. Bu çalışmalarda diş röntgenlerini sınıflandırırken sınıflama işlemlerinin yanı sıra diş segmentasyonu yapmak dişlerin radyografik görüntülerde tanımlanması ve klinik teşhisler için konum bilgisi sağladığından ağız sağlığı alanında kritik bir öneme sahiptir [1].

Ayrıca bu çalışmalar işinde yetkin diş hekimlerinin iş yükünü azaltarak gerek hastaların muayene kalitesini arttırmak gerek gelecek çalışmalar ve bunların sağlayacağı teknolojik gelişmeleri hızlandırmak konusunda oldukça önemli bir potansiyele sahiptir.

1.1. Proje Çalışmasının Amacı ve Önemi

Diş röntgen görüntülerinden hastalıkların yapay zekâ ile sınıflandırılması projesi, diş hekimliği alanında teşhis ve tedavi süreçlerinde önemli bir teknolojik gelişim sunmayı hedeflemektedir. Bu çalışma, panoramik diş röntgenlerinde çürük, dolgu, kanal tedavisi ve implant gibi dental durumların otomatik tespiti ve sınıflandırılması için yapay zekâ algoritmaları kullanmaktadır.

Günümüzde diş hekimleri yoğun klinik ortamlarda sınırlı süreler içerisinde hizmet vermek

durumundadır. Bu proje, hekimlerin iş yükünü iyileştirerek tanı koyma sürecini hem hızlandırmayı hem de doğruluk oranını artırmayı öncelikli hedef olarak belirlemiştir. Yapay zekâ destekli otomatik analiz sistemi, klinik verimliliği artırırken diş hekimlerinin iş yükünü de azaltacaktır.

Projenin diğer bir önemli bileşeni ise bir diş röntgeni veri tabanının oluşturulmasıdır. Bu doğrultuda şimdiye kadar 100'den fazla diş röntgeni toplanmış olup, uzman görüşleri doğrultusunda etiketleme çalışmaları sürdürülmektedir.

2. DİŞ RÖNTGEN GÖRÜNTÜLERİNİN SINIFLANDIRILMASINDA MAKİNE ÖĞRENMESİ UYGULAMALARI

Tıbbi görüntülerin analizi ve sınıflandırılması, makine öğrenmesi ve derin öğrenme tekniklerinin sağlık alanında başarıyla uygulandığı önemli bir alan haline gelmiştir. Diş röntgenleri üzerinde yapılan çalışmalar, diş hekimlerine tanı koymada yardımcı olmak, iş yükünü azaltmak ve teşhis doğruluğunu artırmak amacıyla giderek yaygınlaşmaktadır.

Zeng ve arkadaşları, tıbbi görüntülerden otomatik teşhis raporu oluşturma amacıyla bir çalışma gerçekleştirmişlerdir. Anlamsal Füzyon Ağı (SFNet) olarak adlandırdıkları modelleri, lezyon alanı tespiti ve tıbbi görüntü teşhisi için ayrı modellerden oluşmaktadır. Bu yaklaşım, lezyon tespiti, patolojik bilgi çıkarımı ve rapor oluşturma görevlerini eş zamanlı olarak gerçekleştirmeyi sağlamaktadır. Çalışma kapsamında, Çin'deki Chongqing hastanesinden 25.659 hastanın ultrason görüntüleri ve raporları kullanılmış, ayrıca 7.470 X-ışını görüntüsü içeren Open-i veri kümesinden de yararlanılmıştır [2].

Ünsal ve Adem, panoramik diş röntgenlerinde diş çürüklerinin tespit edilmesi için derin öğrenme yöntemlerini kullanan bir çalışma gerçekleştirmişlerdir. Çalışmada, çürük dişler tedavi yöntemlerine göre dolgu, kanal ve köprü sınıflarına ayrılmıştır. Model performansını artırmak için görüntülere luv-v kanalı ve adaptif histogram eşitleme ön işlemleri uygulanmıştır. Veri seti olarak 553 hastanın panoramik diş röntgenleri kullanılmıştır. Derin öğrenme modellerinden Faster-R-CNN ve Yolov5 karşılaştırılmış, en başarılı sonuçların Yolov5 modeliyle elde edildiği görülmüştür. Dolgu ve kanal görüntülerinde %98, köprü görüntülerinde ise %85 doğruluk oranına ulaşılmıştır [3].

Suryani ve arkadaşları, diş panoramik röntgen görüntülerindeki nesneleri tespit etmek amacıyla Mask R-CNN modelini kullanmışlardır. Çalışma, diş radyografik yorumlamanın

zaman alıcı ve hataya açık sürecini kolaylaştırmayı hedeflemiştir. Veri seti olarak, İran'daki Noor Tıbbi Görüntüleme Merkezi'nden alınan 116 hastanın anonimleştirilmiş panoramik diş röntgenleri kullanılmıştır. Eğitim için 110, test için 6 görüntü kullanılan çalışmada, model panoramik diş görüntüsündeki nesneleri %91-%96 güven seviyesinde tespit edebilmiştir [4].

Hasnain ve arkadaşları, diş radyografilerinin otomatik analizi için konvolüsyonel sinir ağları (CNN) kullanan bir çalışma gerçekleştirmişlerdir. X-ışını görüntüleri "Normal" ve "Etkilenmiş" olarak iki sınıfa ayrılarak model geliştirilmiştir. Veri seti olarak İran'daki Noor Tıbbi Görüntüleme Merkezi'nden alınan yüzden fazla hastanın anonimleştirilmiş panoramik diş röntgenleri kullanılmıştır. Model, eğitim sürecinde %94.80, test aşamasında ise %97.87 doğruluk değeri elde etmiştir. Bu sonuçlar, aynı veri üzerinde test edilen VGG-16 ve ResNet modellerinden daha iyi performans göstermiştir [5].

Schwendicke ve arkadaşları, diş görüntü teşhisi için CNN kullanımını kapsayan sistematik bir inceleme sunmuşlardır. 2000 yılından 2019 yılına kadar yayınlanan çalışmaları kapsayan bu incelemede, CNN'lerin diş hekimliğindeki uygulamaları, kullanılan yöntemler ve CNN performansının insan uzmanlarla karşılaştırılması ele alınmıştır. İncelemede, veri kümesi boyutlarının 10 ile 5.166 görüntü arasında değiştiği (ortalama 1.053 görüntü) belirtilmiştir. En yaygın kullanılan görüntü türü panoramik radyografiler olmuştur. En sık karşılaşılan uygulamalar, %77-%98 doğruluk oranıyla diş sınıflandırması ve %82-%89 doğruluk oranıyla çürük lezyonların tespittir. CNN'leri insan uzmanlarla karşılaştıran on iki çalışmadan üçü CNN'lerin daha iyi, yedisi benzer, biri ise daha kötü performans gösterdiğini bulmuştur [6].

Günümüzde, diş hekimliğinde kullanılan FDA onaylı Overjet ve Pearl gibi yapay zeka platformları dikkat çekmektedir. Overjet, Time dergisinin "2024 yılının en iyi icatları" yazısında kendine yer bulmuş olup, çürükleri kırmızıyla, açıkta kalan sinirleri morla işaretleyerek diş röntgenlerini hastalar için anlaşılır kılmaya yardımcı olmaktadır. Pearl ise makine öğrenmesi ve bilgisayar görüşünü temel alan dental yapay zeka çözümleri sunmaktadır [7, 8].

3. VERİ SETLERİ

3.1. Dental Radiography Veri Seti


Toplamda 1269 adet görsel veri ve 3 adet annotations dosyasından oluşan bu veri seti train, validation ve test olarak klasörlere ayrılmıştır. Eğitim için kullandığımız bu veri setinde 4 adet sınıf bulunmaktadır. Bunlar: Implant, Fillings (Dolgular), Impacted tooth (Gömülü diş) ve Cavity (Çürük) sınıflarıdır.


Veri setinde Bounding Box isimli bir yöntem kullanılmıştır. Bu yöntem ağız röntgenini belli bölgelere bölerek sınıflandırma yapmayı yani ağızdaki farklı dişleri tespit edip birden fazla diş tespit ederek sınıflandırılmasını sağlamayı amaçlamaktadır.

Her bir klasörün altında o klasöre ait _annotations.csv dosyası bulunmaktadır. Bu dosya görsellere ait bilgiler içeren 8 adet kolona sahiptir. Filename şeklinde temsil edilen ilk kolon dosya isimlerini gösterirken, width ve height değerleri kullanılan görsellerin genişlik ve yüksekliğinin kaç piksel olduğunu verir. Bu veri seti için bu değerler her görselde aynıdır fakat veri setinde hem sınıflandırma hem de nesne tespiti amaçlandığı için xmin (nesnenin en soldaki koordinatı), ymin (nesnenin en üst noktasının koordinatı), xmax (nesnenin en sağının koordinatı), ymax (nesnenin en alt noktasının koordinatı) değişkenleriyle ifade edilen nesneye ait koordinatların normalize edilmesi için bu asıl boyut gereklidir. Class kolonunda ise görsel verinin ait olduğu sınıf, metin türünde belirtilmektedir.

Eğitimde kullanılmadan önce bu klasörleri kod yardımıyla her bir görsel ait olduğu sınıfın klasöründe olacak şekilde veri seti yapısı düzenlenmiştir. Eğitimden önce klasör yapısı aşağıdaki şekilde düzenlenmiştir:

dataset





3.2. Dental X-Ray Panoramic Dataset Veri Seti

Toplamda 2871 görüntüden oluşan veri seti YOLO için test, train ve valid olmak üzere üç klasöre ayrılmıştır. Bu veri setinde 31 farklı sınıf vardır.

- 0: Caries (Çürük)
- 1: Crown (Kron)
- 2: Filling (Dolgu)
- 3: Implant (İmplant)
- 4: Malaligned (Düzensiz Hizalanma)
- 5: Mandibular Canal (Alt Çene Kanalı)
- 6: Missing teeth (Eksik Dişler)
- 7: Periapical lesion (Periapikal Lezyon)
- 8: Retained root (Kalan Kök)
- 9: Root Canal Treatment (Kanal Tedavisi)
- 10: Root Piece (Kök Parçası)
- 11: Impacted tooth (Gömülü Diş)
- 12: Maxillary sinus (Maksiller Sinüs)

- 13: Bone Loss (Kemik Kaybı)
- 14: Fracture teeth (Kırık Dişler)
- 15: Permanent Teeth (Kalıcı Dişler)
- 16: Supra Eruption (Aşırı Sürme)
- 17: TAD (Geçici Ankraj Cihazı)
- 18: Abutment (Dayanak)
- 19: Attrition (Aşınma)
- 20: Bone defect (Kemik Defekti)
- 21: Gingival former (Diş Eti Şekillendiricisi)
- 22: Metal band (Metal Bant)
- 23: Orthodontic brackets (Ortodontik Braketler)
- 24: Permanent retainer (Kalıcı Sabitleyici)
- 25: Post-core (Post-Kor)
- 26: Plating (Plak)
- 27: Wire (Tel)
- 28: Cyst (Kist)
- 29: Root resorption (Kök Rezorpsiyonu)
- 30: Primary teeth (Süt Dişleri)

2871 görüntünün içinde bu sınıflara ait toplam 27141 örnek vardır. Bu örneklerin büyük bir bölümü (10058) dolgu örneklerinden oluşmaktadır. Onu 5859 örnek ile gömülü diş ve 3777 örnekle kanal tedavisi izlemektedir. Günlük hayatta en sık karşılaşılan durumlar olduğu için bu örneklere görüntülerde daha fazla rastlanmıştır.

Veri seti klasörlerinin içinde images klasörünün yanında labels klasörü de yer almaktadır. Labels klasörü, her bir görüntü için sınıf bilgilerini içeren etiket dosyalarını barındırmaktadır. Bu dosyalarda, sınıf numaraları ve bounding box (sınırlayıcı kutu) koordinatları bulunur. Her bir etiket dosyası, ilgili görüntüyle aynı ada sahiptir ve .txt formatındadır. Bu etiketler, YOLO modeli tarafından eğitim sırasında kullanılacaktır.

4. BULGULAR VE TARTIŞMA

Bu çalışmada 2 adet hazır veri kümesiyle CNN ve YOLO algoritmaları kullanılarak modeller eğitilmiş, performansları test edilmiştir. Hugging Face platformu üzerinden “AI-RESEARCHER-2024/AI-in-Dentistry” isimli bir çalışma bulunmuştur. 3 adet hazır modeli kullanarak analiz yapan bu uygulamanın Dental Görüntü Segmentasyonu yapan hazır modeli, kendi eğittiğimiz modellere bir örnek ve karşılaştırma teşkil etmesi amacıyla test edilmeye çalışılmıştır. Hastalık tespiti yapmasa da semantik segmentasyon gerçekleştiren bu modelin nesne tespiti aşamasında yararlı olabilecek potansiyele sahip olduğu düşünülmüştür [9].

4.1. Dental Radiography Veri Seti Deney ve Sonuçları

Kaggle platformundan elde edilen Dental Radiography veri setiyle eğitimler ve testler yapılmıştır [10]. Yapılan ilk eğitimde nesne tespiti eğitime dahil edilmemiş deneme amaçlı basit bir CNN modeli oluşturulmuştur. Model %46 accuracy değeri ile oldukça zayıf bir performans göstermiştir.

Layer (type)	Output Shape	Param #
conv2d_2 (Conv2D)	(None, 254, 254, 32)	896
max_pooling2d_2 (MaxPooling2D)	(None, 127, 127, 32)	0
conv2d_3 (Conv2D)	(None, 125, 125, 64)	18,496
max_pooling2d_3 (MaxPooling2D)	(None, 62, 62, 64)	0
flatten_1 (Flatten)	(None, 246016)	0
dense_1 (Dense)	(None, 128)	31,490,176
dense_2 (Dense)	(None, 4)	516

Şekil 4.1 İlk denenen basit CNN modelinin mimarisi

Tablo 4.1 İlk modelin performans metrikleri

Class	precision	recall	f1-score	support
Cavity	0.22	0.17	0.19	12
Fillings	0.49	0.65	0.56	57
Impacted Tooth	0.62	0.29	0.40	17
Implant	0.40	0.32	0.36	31

Model kaydedildikten sonra nesne tespiti için de eğitime dahil edilmesi için model_v2_bbox_added isimli bir model oluşturulmuştur. İlk denemede 10 epoch eğitim yapılmıştır. Ortalama mutlak hatayı hesaplayarak modelin tahminlerinin gerçek değerlerden ne kadar saptığını ölçen bbox_mae (Bounding Box Mean Absolute Error) metriğinin azalırken classification_accuracy metriğinin arttığı gözlemlenmiştir. Bu artışlar oldukça yetersiz ve loss değeri ciddi bir boyutta olduğundan aynı model 30 epochla model tekrar eğitilmiştir.


Bu ikinci eğitimde classification_accuracy metriği en yüksek 0.8202'yi görmesine rağmen son epoch da düşüşe geçmiştir ve 0.7788 değeri ile sonlanmıştır. 0.4751 ile başlayan bbox_mae değeri ise 0.4780 ile biterek classification_accuracy aksine zayıf bir sonuç vermiştir.

Layer (type)	Output Shape	Param #	Connected to
input_layer_21 (InputLayer)	(None, 224, 224, 3)	0	-
flatten_21 (Flatten)	(None, 150528)	0	input_layer_21[0]...
dense_23 (Dense)	(None, 512)	77,070,848	flatten_21[0][0]
classification (Dense)	(None, 4)	2,052	dense_23[0][0]
bbox (Dense)	(None, 4)	2,052	dense_23[0][0]

Şekil 4.2 Bounding box kullanılarak eğitilen nesne tespiti model mimarisi

Model eğitiminde kullanılmayan test klasörüne ait görsel veriler seçilerek Bbox'lar ile birlikte modelin tahmin sonucu çıktı olarak bastırılmıştır. Hem veri setinin test klasöründen hem de bu veri seti dışından görsellerle tahmin yapılmıştır. Model bu aşamada yalnız 1 adet bbox ile tahmin yapabilmektedir dolayısıyla bir görüntüye ait birden fazla nesneye ait sınıf tahmini yapılamamaktadır. Bu sebeple çalışmanın devamında CNN yerine nesne tespiti ve segmentasyonda çok daha iyi sonuçlar veren YOLO kullanılmasına karar verilmiştir. Ayrıca diğer veri setinin sınıf çeşitliliği açısından zengin oluşunun da çalışmamız için daha faydalı olacağına karar verilmiştir.

Tahmin Edilen Sınıf: Implant
Olasılık: 1.0000



Şekil 4.3 Model v.2'nin dışarıdan bir veriyle yapılmış test sonuçları

4.2. Dental X-Ray Panoramic Dataset Veri Seti Deney ve Sonuçları

Deney Kaggle platformundan ulaşılan Dental X-Ray Panoramic Dataset [11] veri seti ile YOLO kullanılarak gerçekleştirilmiştir. YOLO, gerçek zamanlı nesne tespiti için kullanılan bir derin öğrenme modelidir. Model eğitimi için kullanılan YOLOv8 algoritması, derin öğrenme için özel olarak tasarlanmış Evrişimsel Sinir Ağlarına (CNN'ler) dayanan açık kaynaklı bir nesne algılama algoritmasıdır. You Only Look Once (YOLO) nesne algılama algoritmaları ailesinin bir parçası olarak, hız ve doğruluğu dengeleyen gerçek zamanlı nesne algılama yetenekleriyle bilinmektedir.


YOLOv8, görüntüyü bir grid yani ızgara yapısına bölerek ve her hücreinde belli işlemleri

yaparak çalışmaktadır. Öncelikle tespit edilen nesne için sınır kutusu (bounding box) belirler, daha sonra her sınırlanmış kutu için sınıf tahmini yapar ve son olarak bir olasılık değeriyle sınıf tahmin değerini verir.

Kullanılan veri seti 31 farklı sınıfla etiketlenmiştir ve her bir görüntü nesnelerin sınıfı ve konumlarının bilgilerini içeren .txt dosyalarına sahiptir. Modeli eğitirken bu labels klasöründen faydalanılmıştır. Çalışma ortamı olarak Colab tercih edilmiştir ve çalışma zamanı olarak daha hızlı sonuç alabilmek için T4-GPU kullanılmıştır.

Model eğitilirken YOLOv8 modeli kullanılmıştır. Görüntü boyutu 640x640, batch size ise 16 olarak belirlenmiştir. Yani her iterasyonda 16 görüntü işlenmiştir. Model ilk önce 10 epoch ile eğitilmiştir, ama yeterli sonuç alınamadığı görüldüğünde 30 epoch ile eğitmeye karar verilmiştir.

Deney sonucunda modelin görüntüler üzerindeki çıktılarına ait bazı örnekler aşağıda yer almaktadır:



Şekil 4.4 Modelin rastgele iki test verisi üzerindeki çıktıları

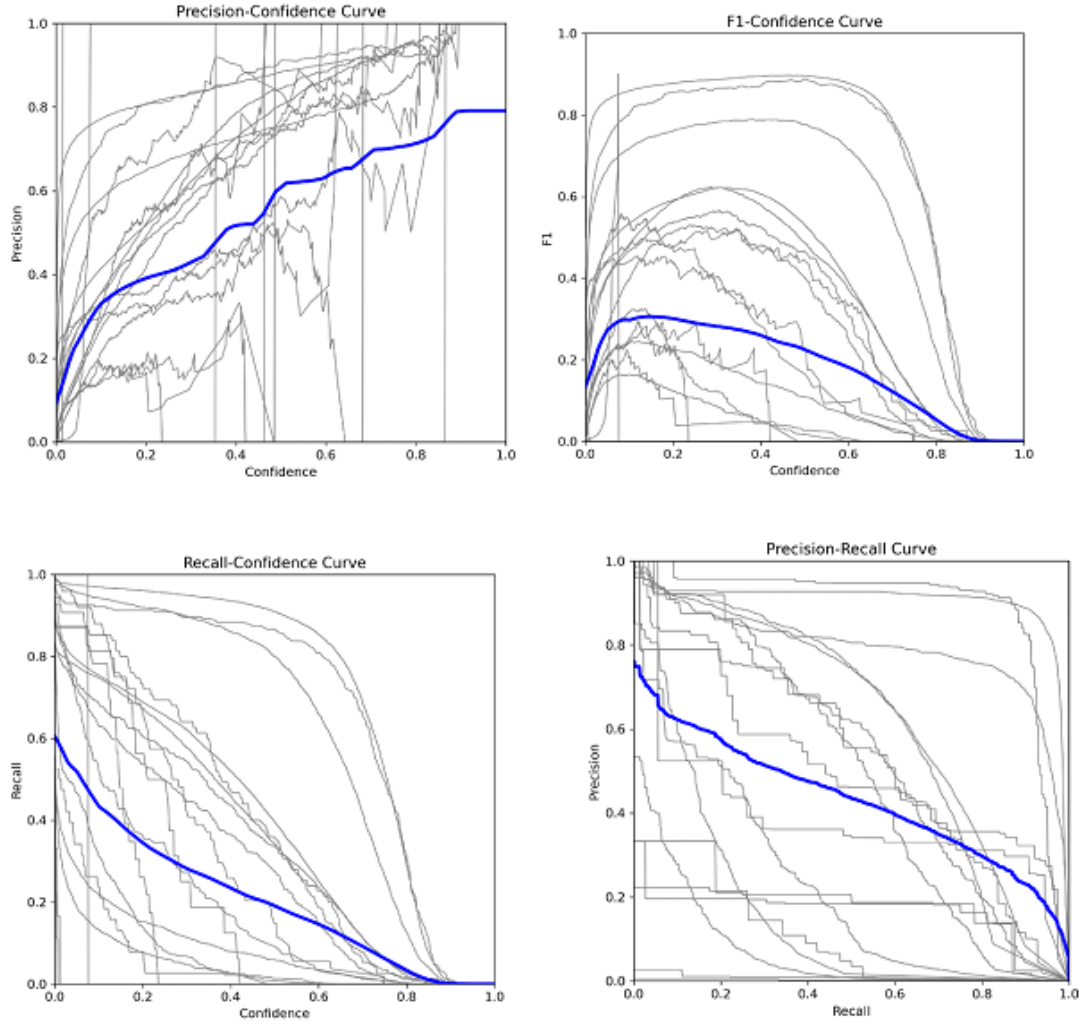
Modelin performans değerlendirmesinde precision, recal, mAP@0.5 ve mAP@0.5-0.95 metriklerine bakılmıştır. Modelin genel performansı toplam 2871 görüntü ve toplam 27141 örnek üzerinden değerlendirilmiştir. Precision ve Recall değerleri sırasıyla %37.2 ve %38.3 olup, modelin doğru pozitif tahminlerde sınırlı bir başarıya sahip olduğunu göstermektedir. Özellikle daha zorlu değerlendirme aralığı olan mAP@0.5-0.95 değerinin %17.5 olması modelin kompleks durumlarda düşük performans gösterdiğini ifade etmektedir.

Class	Images	Instances	Box(P	R	mAP50	mAP50-95):
all	2871	27141	0.372	0.383	0.343	0.175
Caries	614	2180	0.359	0.18	0.162	0.0571
Crown	797	2087	0.625	0.93	0.79	0.506
Filling	2046	10058	0.477	0.719	0.626	0.296
Implant	109	240	0.769	0.912	0.891	0.533
Malaligned	4	5	0	0	0	0
Mandibular Canal	38	75	0.354	0.8	0.509	0.295
Missing teeth	257	541	0.409	0.573	0.471	0.192
Periapical lesion	471	1132	0.279	0.0981	0.0721	0.0191
Retained root	2	6	0	0	0.00175	0.00114
Root Canal Treatment	1061	3777	0.448	0.703	0.611	0.266
Root Piece	181	426	0.43	0.646	0.543	0.229
impacted tooth	2416	5859	0.796	0.965	0.906	0.558
maxillary sinus	27	54	0.309	0.741	0.39	0.262
Bone Loss	212	484	0.5	0.211	0.231	0.105
Fracture teeth	2	2	0	0	0	0
Supra Eruption	8	9	1	0	0.00928	0.00509
abutment	8	15	0	0	0	0
gingival former	2	2	0	0	0	0
metal band	1	1	1	0	0.995	0.399
orthodontic brackets	9	16	0.177	0.75	0.203	0.0914
post - core	25	38	0.165	0.12	0.0805	0.0252
wire	14	23	0.153	0.424	0.167	0.0661
Cyst	1	1	0	0	0	0
Primary teeth	9	110	0.686	0.427	0.561	0.287

Şekil 4.5 Modelin sınıf bazlı performans metrikleri

Sınıf bazında değerlendirildiğinde, dolgu %62.6, gömülü diş %90.6 ve kanal tedavisi %61.1 sınıflarında başarılı sonuçlar elde edilmiştir. Özellikle, örnek sayısı az olan "Malaligned", "Retained root" ve "Fracture teeth" sınıflarında modelin başarısız olduğu görülmektedir. Veri setinin dengesiz yapısı ve bazı sınıflarda düşük örnek sayılarının olması modelin performansını olumsuz etkilemiştir. İlerleyen aşamalarda veri artırımı, epoch sayısının artırılması ve model optimizasyonları ile daha başarılı sonuçlar elde edilmesi hedeflenmektedir.

Model performansı ile ilgili grafiklere aşağıda yer verilmiştir:



Şekil 4.7 Precision, Recall, Confidence, F1 Grafikleri

4.3. Veri Seti Filtreleme

Eğitimde kullanılan veri setinde arttırılma yapıldığı için ve aynı hastaya ait bazı görüntülerde farklı etiketlemeler yapıldığı için veri seti küçültülerek orijinal arttırım yapılmamış hali de elde edilmeye çalışılmıştır. Veri setinde kullanılan görsellerde 2 farklı boyut vardır: 640x640 ve 1615x840. Her hastaya ait tek bir görsel seçilip ayrıca yalnızca 1615x840 boyutlu görseller alınarak hep aynı boyutta görsellerin kullanıldığı filtered isimli yeni bir veriseti oluşturulmuştur.

Başta bazı hastalara ait yalnızca 640x640 boyutunda görseller olduğu için filtreleme sonucunda bu hastalardan hiç görsel alınamamış ve 5084 hastaya ait 9481 görüntüden 4610'u alınmıştır. Sonrasında test klasöründeki tüm görseller 640x640 boyutunda olduğu için filtreleme sonucu test klasörü boş gelmiştir. Kod düzenlenerek eğer hastaya ait

1615x840 boyutunda görsel varsa o, yoksa da var olan görsellerden biri alınarak 5084 hastanın tamamına ait görüntü içeren filtrelenmiş veri seti oluşturulmuştur. Veri setinde sınıf dağılımları ve instance sayıları çok düzensiz olduğundan örneğin bazı sınıflara ait (Fillings) 17958 instance varken bazı sınıflara ait (implant) 609 instance olması performansı olumsuz etkileyeceğinden sınıf sayısı azaltılarak modelin genel performansı arttırılmaya çalışılmıştır.

Filtrelenmiş veri setiyle yapılan eğitim sonucunda missing teeth sınıfı diğer sınıflara nazaran çok düşük performanslı sonuçlar verdiğinden ilerleyen aşamalarda bu sınıf eğitime dahil edilmemiştir.

4.4. Hazır Model Kullanımı

Konuyla ilgili Hugging Face platformu üzerinden “AI-RESEARCHER-2024/AI-in-Dentistry” isimli bir çalışma bulunmuştur. Bu repository 3 adet modeli temel almaktadır:

Calculus and Caries Detection (Calculus ve Çürük Tespiti): Bu model VGG mimarisine dayanmaktadır ve Dental Durum Veri Kümesi üzerinde eğitilmiştir.

Caries Detection (Çürük Tespiti): Bu model Yolov8 modelini kullanarak çürük tespiti yapar, Yolov8 Çürük Dedektöründen alınmıştır.

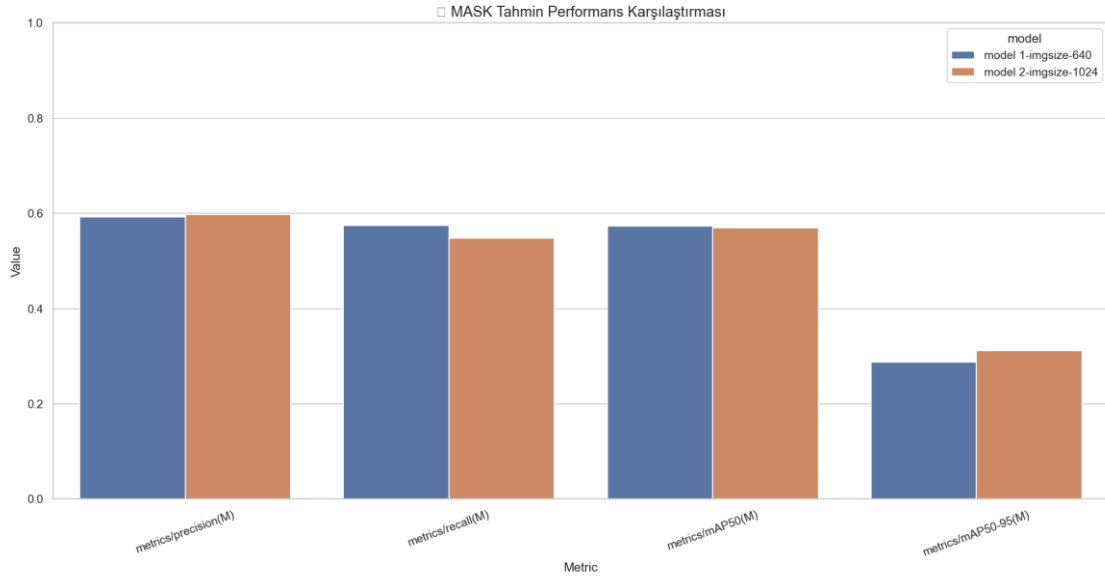
Dental Image Segmentation (Dental Görüntü Segmentasyonu): Bu model, U-Net Modeli ile derin öğrenme yöntemini kullanarak tek çekim panoramik röntgen görüntüsünde semantik segmentasyon gerçekleştirir. Modelin kaynağı Segmentation-of-Teeth-in-Panoramic-X-ray-Image-Using-U-Net'tir.

Çalışmamızda panoramik röntgen görüntüleri kullanıldığı fakat buradaki ilk iki modelde gerçek ağız fotoğrafları temel alındığı için bu iki model bu çalışma için faydalı bulunmamaktadır. 3.model ise nesne tespiti aşamasında yararlı olabilecek potansiyele sahiptir fakat çalışmamız YOLO ile daha iyi performans gösterdiği için segmentasyon artık otomatik gerçekleştirilmekte olup bulunan segmentasyon modelleri çalışma için kullanılmamıştır.

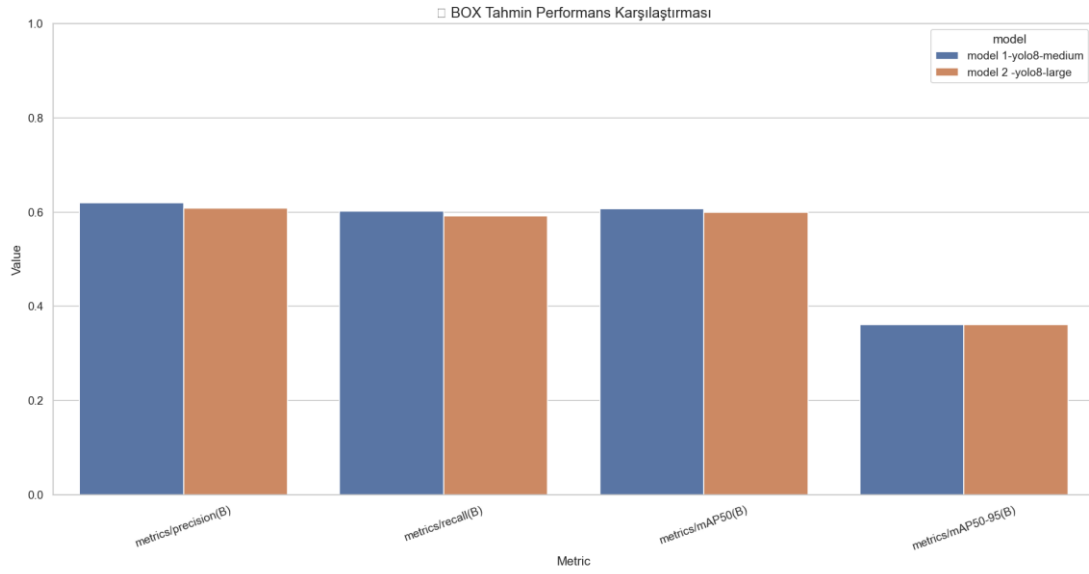
4.5. Eğitim Parametrelerinin Eğitime Etkisi

Filtrelenmiş veri seti üzerinde yapılan çalışmalarda 6 sınıfa ait eğitim sonuçları alınmıştır. Bu eğitimlerden ikisinde aynı optimizör (Adam) kullanılarak model 55'er ve 100'er epoch

eđitilmiřtir. 100 epoch'luk eđitimde imsize 1024 olarak belirlenmiř eđitim 52. Epoch'da sonlanmıřtır. 55 epoch sũren diđer eđitimde ise imsize 640 olarak belirlenmiřtir. İki eđitimde de yolov8m-seg modeli kullanılmıřtır. Diř gũrũntũlerini sınıflandırırken gũzũnũrlũk ȳnemli olduđundan ve filtrelenmiř veri kũmesi bũyũk ȳlũde 1615x840 boyutlu verilerden oluřtuđundan imsize parametresini arttırarak performans arttırılmaya gũliřilmiřtir. Bu eđitim sũresini ciddi ȳlũde uzatmıř fakat performansta istenilen artıřı gũsterememiřtir.



Yine 6 sınıfla yapılan gũliřmada yolo8 medium modeli ve yolo8 large modeli kullanılmıřtır. Large modeli gũk fazla GPU kullanımına neden olması ve eđitim sũresini ciddi oranda arttırmasına rađmen sonuřlar olumlu bir geliřme gũstermemiřtir.



5. SONUÇLAR

Bu proje çalışmasında 2 farklı veri kümesi ile 2 farklı derin öğrenme algoritması (CNN ve YOLO) kullanılarak modeller geliştirilmiş, sonuçları test edilmiştir. CNN ve Dental Radiography seti kullanılarak eğitilen modelinin pratikte test görselleri üzerinde güzel sonuçlar verdiği fakat birden fazla nesne tespit edemeyip tek bbox'a ait tek bir sınıflandırma tespit edilmiştir. Bu durum ağız içerisindeki birden fazla hastalık veya sınıflandırma bulunması durumunda modelin yalnızca en çok emin olduğu bir sınıfı bulacağı anlamına gelmektedir. Dolayısıyla ileride istenilen performansı sağlamak adına daha detaylı nesne tespiti ve birden fazla nesneye ait sınıflandırma üzerine yoğunlaşılması hedeflenmektedir. YOLO'nun çoklu nesne tespitinde CNN'den daha iyi performans verdiği gözlenmiş, çalışmanın devamında Dental X-Ray Panoramic Dataset veri seti ve YOLO algoritması ile çalışmaya karar verilmiştir.

YOLO algoritması ve Dental X-Ray Panoramic Dataset kullanılarak eğitilen modelin tahminlerinde nesne tespiti sonuçları tatmin edicidir. Model ağız röntgeni üzerinde birden fazla bbox'u ayrı ayrı sınıflandırabilmektedir. İleri aşamalarda 30 adet sınıfı bulunan bu modelin eğitim performansını arttırmak amacıyla daha gelişmiş YOLO teknikleri kullanmak hedeflenmiştir bunun için YOLO'nun seg modelinden faydalanılmış veri üzerinde de CLAHE tekniği kullanılarak görsel kalitesi arttırılmıştır.

Çalışmaya katkı sunması için hazır bir modelde test edilerek kendi modellerimizle karşılaştırılmak istenmiştir. Tam olarak istenilen şekilde sınıflandırma yapan bir model bulunamasa da nesne tespiti yapan bir model bulunmuştur. Modelin yalnızca alt ve üst çene olarak segmentasyon yapmasının çalışma için uygun olmadığı düşünülmüştür. Bu alanda segmentasyon yapılan farklı modeller de bulunmuş ve roboflow¹ üzerinden test edilmiştir. Fakat hem “Dental X-Ray Panoramic Dataset” veri setinin sınıf sayısının ve örneğinin fazla oluşu hem de nesne tespiti konusunda daha performanslı olan YOLO algoritmasını kullanmaya uygun oluşu sebebiyle segmentasyon için ayrı bir işlem yapmak tercih edilmemiştir. Çalışmamızı karşılaştırmak için ise bu veri setiyle eğitilmiş modelin best.pt dosyasındaki ağırlıkları kullanılarak alınan sonuçlar bizim eğittiğimiz modellerle karşılaştırılmıştır.

Çalışma süresince kendi veri setimizi oluşturmak için panoramik diş görüntüleri toplanmıştır. 100’den fazla görüntü toplandıktan sonra bunların etiketlenmesi için çalışmalar yapılmıştır. 4 farklı dişçi tarafından görüntüler yalnızca yazılı olarak etiketlenmiş ve bunlar bir excel dosyası haline getirilmiştir. Veri sayısının yetersiz oluşu (111 hasta) ve görüntülerin eğitimde kullanılabilecek bir etiketlendirme formunda olmaması sebebiyle topladığımız veriler kullanılamamıştır. Bu verilerin dijital formatta etiketlenerek sonraki çalışmalarda kullanılabileme potansiyeli bulunmaktadır. Bu aşamada elimizdeki hazır veri setinden yararlanarak sonuçları iyileştirmeye öncelik vermek amaçlanmıştır.

Başlangıçta 31 sınıf ile eğitilen model, istenilen doğruluk seviyesine ulaşamamıştır. Yapılan analizler sonucunda, özellikle örnek sayısı az olan ve klinik olarak daha az yaygın sınıfların model performansını olumsuz etkilediği gözlemlenmiştir. Bu nedenle, sınıf sayısının azaltılmasına ve yalnızca örnek sayısı yeterli ve yaygın olan sınıfların kullanılmasıyla model eğitime devam edilmesine karar verilmiştir.

Bu doğrultuda eğitim süreci, aşağıda belirtilen 5 sınıf üzerinden yeniden yapılandırılmıştır:

- 0: Caries (Çürük)
- 1: Filling (Dolgu)

¹ <https://universe.roboflow.com/salud360/dental-qbbud/model/2>

- 2: Implant (İmplant)
- 3: Root Canal Treatment (Kanal Tedavisi)
- 4: Impacted Tooth (Gömülü Diş)

Sınıf sayısının azaltılması sürecinde öncelikle, veri kümesinde bulunan tüm görüntülerin etiketleri yeni sınıf indekslerine göre yeniden düzenlenmiştir. Etiket güncellemesinin ardından, artık herhangi bir etiketi kalmamış olan görüntüler tespit edilerek veri kümesinden çıkarılmış, böylece veri setinde oluşabilecek gürültülerin önüne geçilmiştir.

Görüntü kalitesini artırmak ve modelin segmentasyon başarımını iyileştirmek amacıyla, kalan görüntülere CLAHE yöntemi uygulanmıştır. Bu işlem, görüntülerin kontrastını artırarak özellikle düşük ışık veya kontrast koşullarında bile detayların daha belirgin hale gelmesini sağlamıştır.

İlk aşamada kullanılan model, nesne tespiti üzerine çalışan YOLOv8 mimarisi iken, sınıf sayısının azaltıldığı yeni aşamada daha hassas analizler yapılabilmesi adına YOLOv8-seg modeli tercih edilmiştir. Bu model, sadece nesnelerin konumlarını sınırlayıcı kutularla değil, aynı zamanda piksel düzeyinde segmentasyon ile tespit etmeyi hedeflemektedir. Böylece diş üzerinde yer alan lezyonların sınırlarının daha doğru belirlenmesi ve sınıf ayrımının daha hassas yapılması amaçlanmıştır.

Model Konfigürasyon Karşılaştırması

Özellik	İlk Model (31 Sınıf)	İkinci Model (5 Sınıf)
Mimari	YOLOv8 (Nesne Tespiti)	YOLOv8-seg (Örnek Segmentasyonu)
Model Boyutu	YOLOv8 Nano	YOLOv8 Medium
Sınıf Sayısı	31 sınıf	5 sınıf
Eğitim Epoch Sayısı	30 epoch	25 epoch
Görüntü Boyutu	640x640 piksel	640x640 piksel
Batch Boyutu	16	8
Görüntü Ön İşleme	Standart	CLAHE iyileştirmesi uygulandı

Eğitim Veri Seti	Tüm sınıfları içeren tam veri seti	Filtrelenmiş veri seti, ilgisiz etiketli görüntüler çıkarıldı
------------------	------------------------------------	---

31 sınıflı nesne tespit modelinden, sadece 5 sınıfa odaklanan segmentasyon modeline geçilmesiyle birlikte, model performansında tüm metriklerde gözle görülür bir iyileşme elde edilmiştir. Sınıf sayısının azaltılması ve eğitim verisi açısından yeterli olan, aynı zamanda klinik olarak daha önemli sınıflara odaklanması oldukça etkili olmuştur.

En dikkat çekici gelişme, genel model başarımında yaşanmıştır. Genel mAP50 değeri 0.343'ten 0.694'e çıkarak %102.3 oranında artış göstermiştir. Daha da etkileyici olan ise, farklı IoU eşiklerinde ölçülen mAP50-95 değerinde yaşanan %118.3'lük artıştır. Bu da modelin farklı zorluk seviyelerinde daha tutarlı ve başarılı tahminler yaptığını göstermektedir. Ayrıca, doğruluk değeri 0.372'den 0.74'e yükselmiş ve bu da yanlış pozitif tespitlerin önemli ölçüde azaldığını ortaya koymuştur. Bu gelişme, modelin klinik kullanım açısından daha güvenilir hale geldiğini göstermektedir.

Segmentasyon modeline geçilmesiyle birlikte piksel düzeyinde değerlendirme yapma imkanı da doğmuştur. Mask precision değeri 0.697, mask recall değeri 0.634 olarak ölçülmüş; mask mAP50 değeri ise 0.646 olmuştur. Bu değerler, modelin sadece nesneleri bulmakla kalmayıp, onların sınırlarını da oldukça başarılı şekilde çizbildiğini göstermektedir.

Performans Metrikleri Karşılaştırması

Metrik	İlk Model	İkinci Model	İyileşme
Genel mAP50	0.343	0.694	+%102.3
Genel mAP50-95	0.175	0.382	+%118.3
Box Precision	0.372	0.74	+%98.9
Box Recall	0.383	0.677	+%76.8
Mask Precision	-	0.697	Yeni Metrik

Mask Recall	-	0.634	Yeni Metrik
Mask mAP50	-	0.646	Yeni Metrik
Mask mAP50-95	-	0.306	Yeni Metrik

KAYNAKLAR

- [1] M. K. Dhar and M. Deb, “S-R2F2U-Net: A single-stage model for teeth segmentation,” *arXiv*, 2023. [Online]. Available: <https://arxiv.org/abs/2204.02939>.
- [2] Zeng, X., Wen, L., Xu, Y., & Ji, C. (2020). Generating Diagnostic Report for Medical Image by High-middle-level Visual Information Incorporation on Double Deep Learning Models. *Computer Methods and Programs in Biomedicine*, 197, 105700.
- [3] Ünsal, Ü., & Adem, K. (2023). Diş Görüntüleri Üzerinde Görüntü İşleme ve Derin Öğrenme Yöntemleri Kullanılarak Çürük Seviyesinin Sınıflandırılması. *Uluslararası Sivas Bilim Ve Teknoloji Üniversitesi Dergisi*, 2(2), 30-53.
- [4] Suryani, D., Shoumi, M., & Wakhidah, R. (2021). Object detection on dental x-ray images using deep learning method. *IOP Conference Series: Materials Science and Engineering*, 1073, 012058.
- [5] Hasnain, M. A., Ali, S., Malik, H., Irfan, M., & Maqbool, M. S. (2023). Deep Learning-Based Classification of Dental Disease Using X-Rays. *Journal of Computational and Biophysical Insights*, 5(01), 82-95.
- [6] Schwendicke, F., Golla, T., Dreher, M., & Krois, J. (2019). Convolutional neural networks for dental image diagnostics: A scoping review. *Journal of Dentistry*, 91, 103226.
- [7] <https://time.com/7094716/overjet/>
- [8] <https://www.hellopearl.com/>
- [9] <https://huggingface.co/AI-RESEARCHER-2024/AI-in-Dentistry>
- [10] <https://www.kaggle.com/datasets/imtkaggleteam/dental-radiography/data>
- [11] <https://www.kaggle.com/datasets/lokisilvres/dental-disease-panoramic-detection-dataset/data>
- [12] <https://universe.roboflow.com/salud360/dental-qbbud/model/2>